



دانشگاه صنعتی امیرکبیر  
(پلی تکنیک تهران)

دانشکده ریاضی و علوم کامپیوتر  
استاد درس: دکتر مهدی دهقان  
پاییز ۱۴۰۳

# مقدمه‌ای بر SVD و کاربرد آن در دسته‌بندی داده‌ها

جبر خطی عددی

۹۹۲۵۰۲۳

هلیا صاحب‌قدم

---

## فهرست مطالب

۳	۱ چکیده
۴	۲ مقدمه
۴	۱.۲ تجزیه مقادیر منفرد
۵	۲.۲ محاسبه ی تجزیه مقادیر منفرد
۹	۳.۲ کاربرد های تجزیه مقادیر منفرد
۱۱	۳ دسته بندی ارقام دست نویس
۱۱	۱.۳ شرح مساله
۱۱	۲.۳ تنسور
۱۲	۳.۳ دیتاست
۱۳	۴.۳ یک الگوریتم ساده برای طبقه بندی
۱۳	۵.۳ دسته بندی داده ها با پایه های SVD
۱۹	۴ فاصله تانژانت
۲۱	۱.۴ تبدیلات
۲۴	۵ نتیجه گیری

## ۱ چکیده

در دنیای یادگیری ماشین و علوم داده، تجزیه مقدار منفرد به عنوان یکی از تکنیک‌های کلیدی برای کاهش ابعاد داده و استخراج ویژگی‌های اساسی استفاده می‌شود. این روش با کاهش نویز و حفظ اطلاعات مهم، ابزاری قدرتمند برای بهبود عملکرد مدل‌های طبقه‌بندی است. در این پژوهش، ابتدا اصول و مبانی تجزیه مقدار منفرد معرفی شده و سپس نحوه محاسبه و کاربردهای آن بررسی می‌شود.

یکی از کاربردهای مهم آن در دسته‌بندی ارقام دست‌نویس است. در این مقاله، یک الگوریتم ساده برای طبقه‌بندی این داده‌ها با استفاده از پایه‌های تجزیه مقادیر منفرد ارائه شده است. نتایج آزمایشات نشان می‌دهد که این تکنیک نه تنها پیچیدگی محاسباتی را کاهش می‌دهد، بلکه عملکرد مدل‌های طبقه‌بندی را نیز بهبود می‌بخشد. علاوه بر این، تاثیر تغییرات و تداخلات بر فاصله تانژانت بررسی شده است.

**واژه‌های کلیدی:** تجزیه مقدار منفرد، کاهش ابعاد، استخراج ویژگی، طبقه‌بندی ارقام دست‌نویس، فاصله تانژانت، تنسور

## ۲ مقدمه

تجزیه مقادیر منفرد<sup>۱</sup> یک تکنیک پایه‌ای در فاکتورگیری ماتریس است که ساختارهای پنهان را استخراج، ابعاد داده‌ها را کاهش و تفسیرپذیری داده‌ها را افزایش می‌دهد. این روش ماتریس  $A$  را به صورت  $U\Sigma V^T$  تجزیه می‌کند، که در آن  $U$  و  $V$  ماتریس‌های متعامد هستند و  $\Sigma$  شامل مقادیر منفرد<sup>۲</sup> مرتب شده است که ویژگی‌های غالب داده را نشان می‌دهند. برخلاف تجزیه QR، SVD، ردیف‌ها و ستون‌ها را به طور متقارن مدیریت کرده و بینش عمیق‌تری ارائه می‌دهد و تجزیه خود را به مسائل خاص تطبیق می‌دهد. SVD در روش‌هایی مانند تحلیل مؤلفه‌های اصلی<sup>۳</sup> و حل مسائل کمترین مربعات<sup>۴</sup> برای ماتریس‌های غیرمربعی نقش کلیدی دارد. تطبیق‌پذیری و توانایی آن در اولویت‌بندی مؤلفه‌های تأثیرگذار، آن را به ابزاری بی‌بدیل در داده‌کاوی، پردازش سیگنال و علوم محاسباتی تبدیل کرده است.

## ۱.۲ تجزیه مقادیر منفرد

هر ماتریس  $A$  با ابعاد  $m \times n$  که  $m \geq n$ ، می‌تواند به صورت زیر تجزیه شود:

$$A = U \begin{pmatrix} \Sigma \\ 0 \end{pmatrix} V^T,$$

که در آن  $U \in \mathbb{R}^{m \times m}$  و  $V \in \mathbb{R}^{n \times n}$  ماتریس‌های متعامد هستند و  $\Sigma \in \mathbb{R}^{n \times n}$  ماتریسی قطری است به صورت زیر:

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n),$$

که در آن:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq 0.$$

ستون‌های  $U$  و  $V$  را به ترتیب بردارهای تکین چپ و راست می‌نامند و عناصر قطری  $\sigma_i$  را مقادیر تکین مثبت می‌نامند. تجزیه مقادیر منفرد را بصورت نمادین در شکل زیر نمایش می‌دهیم.

$$\begin{array}{c} \boxed{A} \\ m \times n \end{array} = \begin{array}{c} \boxed{U} \\ m \times m \end{array} \begin{array}{c} \boxed{\begin{array}{c} 0 \\ \diagdown \\ 0 \end{array}} \\ m \times n \end{array} \boxed{V^T}$$

شکل ۱: نمایش SVD

<sup>1</sup>Singular Value Decomposition (SVD)

<sup>2</sup>Singular Values

<sup>3</sup>Principal Component Analysis (PCA)

<sup>4</sup>Least-Squares Problems

## ۲.۲ محاسبه ی تجزیه مقادیر منفرد

در اینجا نحوه محاسبه SVD را بیان می کنیم. (برابر با تعداد مقادیر تکین مثبت است  $r$ )  
**گام ۱:** ماتریس  $A^T A$  را تشکیل دهید و جذر مقادیر ویژه ی آن را با  $\sigma_1 = \sqrt{\lambda_1}, \dots, \sigma_r = \sqrt{\lambda_r}$  قرار می دهیم (مقادیر تکین به صورت نزولی در ماتریس  $\Sigma$  قرار گرفته اند):

$$\Sigma_1 = \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_r \end{bmatrix}_{r \times r}, \quad \Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix}_{m \times n}$$

**گام ۲:** بردارهای ویژه ی یک شده  $A^T A$  را با  $v_1, v_2, \dots, v_n$  نمایش داده و ماتریس  $V$  را به صورت زیر تشکیل دهید:

$$V = [v_1, v_2, \dots, v_n]$$

**گام ۳:** برای  $i = 1, 2, \dots, r$  بردارهای  $u_i$  را به صورت زیر می سازیم:

$$u_i = \frac{1}{\sigma_i} A v_i$$

**گام ۴:** بردارهای  $u_{r+1}, u_{r+2}, \dots, u_m$  را طوری بدست می آوریم که ماتریس  $U$  متعامد باشد.

$$U = [u_1, u_2, \dots, u_r, u_{r+1}, u_{r+2}, \dots, u_m]$$

**گام ۵:** ماتریس های  $V, \Sigma, U$  تشکیل شده اند، لذا تجزیه ی SVD ماتریس  $A$  به صورت زیر خواهد بود:

$$A = U \Sigma V^T$$

برای اشاره به مفید بودن تجزیه، یک مسئله مینیم سازی را در نظر بگیرید:

$$\min_X \|F - X\|_2$$

که در آن  $\text{rank}(X) = r$  و  $\text{rank}(F) = n = r < n$ . حل این مسئله بهترین ماتریس رتبه  $r$  را که تقریباً ماتریس  $F$  را برآورد می کند، به دست می دهد. تجزیه مقادیر منفرد (SVD) راه حل را به صورت زیر ارائه می دهد:

$$X = U \cdot \Sigma_r \cdot V^H$$

که در آن فقط شامل  $r$  مقدار منفرد اول از  $\Sigma$  اصلی است.

## مثال ۱.۲: تجزیه مقادیر منفرد (SVD)

برای درک بهتر الگوریتم SVD به مثال زیر توجه کنید. فرض کنید ماتریس زیر داده شده است:

$$A = \begin{bmatrix} 1 & -1 \\ 2 & 1 \\ 0 & 3 \end{bmatrix}$$

گام ۱: تشکیل  $AA^T$  و  $A^T A$ 

ابتدا ماتریس های  $AA^T$  و  $A^T A$  را محاسبه می کنیم:

$$A^T A = \begin{bmatrix} 5 & 1 \\ 1 & 11 \end{bmatrix}, \quad AA^T = \begin{bmatrix} 2 & 1 & -3 \\ 1 & 5 & 3 \\ -3 & 3 & 9 \end{bmatrix}$$

گام ۲: یافتن مقادیر و بردارهای ویژه  $AA^T$ 

برای  $AA^T$  مقادیر ویژه ( $\lambda$ ) و بردارهای ویژه ( $u$ ) به صورت زیر محاسبه می شوند:

$$\lambda_1 \approx 11.1623, \quad u_1 = \begin{bmatrix} -0.2475 \\ 0.3913 \\ 0.8863 \end{bmatrix}$$

$$\lambda_2 \approx 4.8377, \quad u_2 = \begin{bmatrix} 0.5216 \\ 0.8247 \\ -0.2185 \end{bmatrix}$$

$$\lambda_3 \approx 0, \quad u_3 = \begin{bmatrix} -0.8165 \\ 0 \\ -0.4082 \end{bmatrix}$$

پس ماتریس  $U$  به صورت زیر خواهد بود:

$$U = \begin{bmatrix} -0.2475 & 0.5216 & -0.8165 \\ 0.3913 & 0.8247 & 0 \\ 0.8863 & -0.2185 & -0.4082 \end{bmatrix}$$

گام ۳: یافتن مقادیر و بردارهای ویژه  $A^T A$ 

برای  $A^T A$  مقادیر و بردارهای ویژه به صورت زیر هستند:

$$\lambda_1 \approx 11.1623, \quad v_1 = \begin{bmatrix} 0.1602 \\ 0.9871 \end{bmatrix}$$

$$\lambda_2 \approx 4.8377, \quad v_2 = \begin{bmatrix} -0.9871 \\ 0.1602 \end{bmatrix}$$

پس ماتریس  $V$  به صورت زیر است:

$$V = \begin{bmatrix} 0.1602 & -0.9871 \\ 0.9871 & 0.1602 \end{bmatrix}$$

### گام ۴: محاسبه مقادیر منفرد و تشکیل $\Sigma$

مقادیر منفرد ماتریس  $A$  با جذر مقادیر ویژه  $A^T A$  به دست می آیند:

$$\sigma_1 = \sqrt{\lambda_1} \approx 3.3410, \quad \sigma_2 = \sqrt{\lambda_2} \approx 2.1995$$

ماتریس قطری  $\Sigma$  به صورت زیر است:

$$\Sigma = \begin{bmatrix} 3.3410 & 0 \\ 0 & 2.1995 \\ 0 & 0 \end{bmatrix}$$

### گام ۵: بازسازی $A$ با $U\Sigma V^T$

در نهایت، ماتریس  $A$  با ضرب  $U$ ،  $\Sigma$  و  $V^T$  به صورت زیر بازسازی می شود:

$$A = U\Sigma V^T$$

$$\begin{bmatrix} 1 & -1 \\ 2 & 1 \\ 0 & 3 \end{bmatrix} = \begin{bmatrix} -0.2475 & 0.5216 & -0.8165 \\ 0.3913 & 0.8247 & 0 \\ 0.8863 & -0.2185 & -0.4082 \end{bmatrix} \begin{bmatrix} 3.3410 & 0 & 0 \\ 0 & 2.1995 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0.1602 & 0.9871 \\ -0.9871 & 0.1602 \end{bmatrix}^T$$

$$A = U \cdot \Sigma \cdot V^T$$

### ماتریس های پایه ی عمود

ماتریس  $F$  را می توان به صورت مجموع ماتریس های رتبه یک نوشت:

$$F = U \cdot \Sigma \cdot V^T = \sum_{i=1}^n \sigma_i u_i v_i^T$$

که در آن  $\sigma_i$  مقادیر منفرد هستند و  $u_i$  و  $v_i$  به ترتیب ستون های ماتریس های  $U$  و  $V$  هستند.

### شهود هندسی


در تصویر زیر می توان شهود هندسی تجزیه مقادیر منفرد را مشاهده نمود.

چرخش یا بازتاب اولیه ( $V^T$ )

این ماتریس، فضای ورودی را به گونه ای تغییر می دهد که محورهای مختصات جدید با جهت های خاص ماتریس  $A$  همپایه شوند.

مقیاس گذاری ( $\Sigma$ )

در این مرحله، هر محور جدید با یک مقدار مشخص (مقدار منفرد) مقیاس می شود. این مقادیر نشان دهنده میزان کشیدگی یا فشردگی در آن جهت هستند.



شکل ۲: شهود هندسی SVD

چرخش یا بازتاب نهایی ( $U$ ) این ماتریس، فضای تغییر یافته را دوباره چرخانده یا بازتاب می‌دهد تا به فضای خروجی منتقل شود.

مثال فرض کنید  $A$  یک ماتریس  $2 \times 2$  باشد. این ماتریس می‌تواند یک بیضی را از یک دایره واحد ایجاد کند:

- $V^T$  دایره را در فضای ورودی به گونه‌ای می‌چرخاند که محورهای بیضی با محورهای مختصات هماهنگ شوند.

- $\Sigma$  شعاع‌های دایره را در جهت‌های مختلف کشیده یا فشرده می‌کند، به طوری که یک بیضی حاصل می‌شود.

- $U$  این بیضی را به فضای خروجی می‌چرخاند.

به طور خلاصه، SVD نشان می‌دهد که هر تبدیل خطی می‌تواند به سه مرحله هندسی قابل فهم تقسیم شود: چرخش، مقیاس‌گذاری، و چرخش مجدد.




## ۳.۲ کاربرد های تجزیه مقادیر منفرد

تجزیه مقادیر منفرد یکی از ابزارهای قدرتمند در جبر خطی است که کاربردهای گسترده‌ای در حوزه‌های مختلف دارد. در اینجا پنج کاربرد متداول آن را نام می‌بریم:

### ۱. کاهش ابعاد داده

در مجموعه‌های داده با ابعاد بالا، تحلیل و پردازش داده‌ها می‌تواند پیچیده و زمان‌بر باشد. SVD با کاهش ابعاد داده‌ها به فضای با بعد کمتر کمک می‌کند، به طوری که اطلاعات اصلی حفظ می‌شوند. این روش به ویژه در تحلیل مولفه‌های اصلی (PCA) به کار می‌رود. کاهش ابعاد به بهبود عملکرد الگوریتم‌های یادگیری ماشین و کاهش هزینه‌های محاسباتی منجر می‌شود. به عنوان مثال، در داده‌های تصویری، می‌توان تعداد پیکسل‌ها را بدون از دست دادن اطلاعات مهم کاهش داد.



شکل ۳: تحلیل مولفه‌های اصلی

### ۲. فشرده‌سازی تصویر

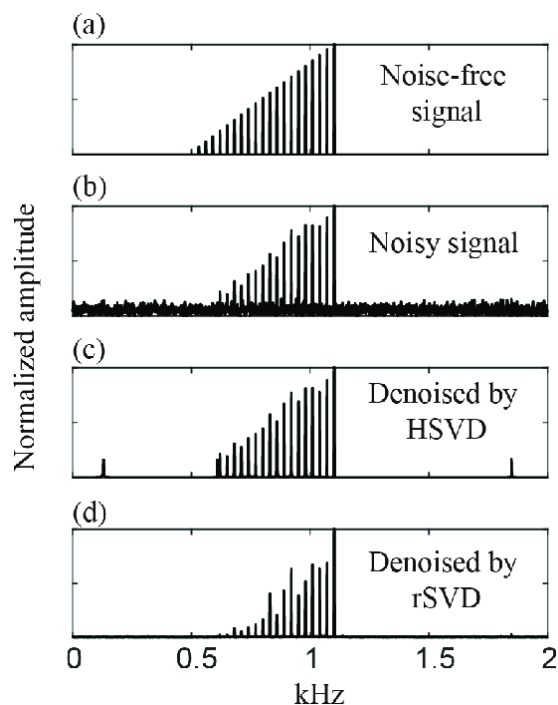
SVD برای فشرده‌سازی تصاویر به کار می‌رود. در این روش، ماتریس تصویر با استفاده از مقادیر منفرد بزرگ‌تر بازسازی می‌شود. با انتخاب تعداد محدودی از این مقادیر، می‌توان حجم داده‌ها را کاهش داد و تصویر را فشرده کرد. این فرآیند باعث صرفه‌جویی در فضای ذخیره‌سازی و پهنای باند انتقال می‌شود. اگرچه برخی از جزئیات تصویر از دست می‌روند، اما برای بسیاری از کاربردها، این کاهش کیفیت قابل قبول است.

### ۳. حل مسائل معکوس و سیستم‌های خطی

در بسیاری از مسائل علمی و مهندسی، باید معادلات خطی را حل کرد. اما هنگامی که این معادلات به صورت بدووضع (ill-posed) باشند، روش‌های معمول ممکن است دقت کافی نداشته باشند. SVD یک راه حل پایدار برای چنین مسائلی فراهم می‌کند. با استفاده از SVD، می‌توان به طور موثری سیستم‌های معادلات خطی با ماتریس‌های نامتعادل یا بزرگ را حل کرد. همچنین، این روش برای یافتن تقریب بهترین جواب در مسائل معکوس، جایی که راه‌حل دقیقی وجود ندارد، مفید است.

#### ۴. کاهش نویز

در پردازش سیگنال و تصویر، کاهش نویز یکی از چالش های مهم است. SVD می تواند با حذف مقادیر منفرد کوچک تر که معمولاً نشان دهنده نویز هستند، به کاهش نویز کمک کند. این روش به طور موثر ساختارهای اصلی داده را حفظ کرده و نویز را حذف می کند. در پردازش تصاویر، این فرآیند می تواند به تصاویر واضح تر و سیگنال های با کیفیت تر منجر شود.




شکل ۴: کاهش نویز

#### ۵. توصیه گر ها

سیستم های توصیه گر برای پیشنهاد آیتم هایی مانند فیلم، کتاب، یا محصولات به کاربران استفاده می شوند. SVD به عنوان یکی از تکنیک های اصلی در این سیستم ها، با تجزیه ماتریس تعاملات کاربر-آیتم، الگوهای پنهان را استخراج می کند. با کاهش رتبه ماتریس و فاکتورگیری، سیستم می تواند پیش بینی های دقیقی برای علایق کاربران ارائه دهد. این روش به ویژه در سیستم های بزرگی که تعداد کاربران و آیتم ها زیاد است، به کار می رود و به بهبود دقت و کارایی سیستم های توصیه گر کمک می کند.

به طور خلاصه، SVD به دلیل توانایی خود در تحلیل و پردازش داده ها به روشی بهینه و موثر، در بسیاری از کاربردهای علمی و صنعتی به کار گرفته می شود.



شکل ۵: تحلیل مولفه‌های اصلی

## ۳ دسته بندی ارقام دست نویس

### ۱.۳ شرح مساله

طبقه‌بندی فرآیندی است که طی آن داده‌ها یا اشیاء بر اساس ویژگی‌ها یا خصوصیاتشان به کلاس‌ها یا دسته‌های از پیش تعریف شده دسته‌بندی می‌شوند. مسئله‌ی طبقه‌بندی کاراکترها در این زمینه به عنوان یکی از مسائل بنیادی در نظر گرفته شده و الگوریتم‌های طبقه‌بندی متعددی وجود دارند که در حوزه‌های خاص به صورت کم و بیش عملکرد مناسبی دارند.

راه‌های مختلفی برای تقسیم‌بندی این مسئله به دسته‌بندی‌های اصولاً متفاوت وجود دارد. از این رو، طبیعی است که مناسب‌ترین روش‌ها برای حل مسئله در شرایط مختلف ممکن است متفاوت باشند. بسیاری از الگوریتم‌ها بر اساس نظریه‌های ریاضی مختلف ابداع شده‌اند. جبر خطی، تحلیل تابعی و آمار تنها چند مورد از این نظریه‌ها هستند.


یکی از راه‌های تمایز بین الگوریتم‌ها، بررسی نحوه‌ی نمایش کاراکترها است. به عنوان مثال، وقتی با قلم می‌نویسیم، یک نماد شکلی بر روی کاغذ ثبت می‌شود. این شکل را می‌توان حداقل به دو روش نمایش داد - به صورت یک تصویر پیکسلی یا به صورت منحنی‌هایی در یک صفحه. بنابراین، ساختار داده‌های ورودی تأثیر عمده‌ای بر نحوه‌ی ساخت الگوریتم دارد. ممکن است در این مورد نمایش منحنی را ترجیح دهیم زیرا شکل‌های اصلی که قصد طبقه‌بندی آن‌ها را داریم، منحنی هستند و با حرکت منحنی‌وار دست نوشته می‌شوند و نه به صورت نقاط یا پیکسل‌هایی با شدت‌های مختلف. با داشتن مجموعه‌ای از اعداد دست‌نویس که به صورت دستی طبقه‌بندی شده‌اند (مجموعه آموزش)، هدف طبقه‌بندی مجموعه‌ای از اعداد ناشناخته (مجموعه تست) است.

### ۲.۳ تنسور

ساختارها یا مقادیر ریاضی مانند بردارها و ماتریس‌ها گاهی اوقات برای توصیف ماهیت واقعی داده‌ها در زمینه‌های مختلف پردازش سیگنال مناسب نیستند. این ساختارها به راحتی می‌توانند به ساختارهای عمومی‌تر و با مرتبه بالاتر گسترش یابند که به آن‌ها آرایه‌های چندبعدی، ماتریس‌های چندبعدی یا، همان‌طور که در این گزارش به آن‌ها اشاره خواهد شد، به سادگی تنسورها گفته می‌شود. بردارها و ماتریس‌ها به ترتیب معادل تنسورهای مرتبه اول و دوم هستند. الگوریتم ساخته شده عمدتاً بر اساس حالت خاصی از این نظریه برای تنسورهای مرتبه سوم است. بنابراین، بیشتر نظریه‌های ارائه شده در این بخش به تنسورهای مرتبه سوم مربوط می‌شود.

### ۳.۳ دیتاست

دیتاستی که در این مقاله مورد بحث می باشد [۳] ارقام دست نویس از ۰ تا ۹ است که شامل ۷۲۹۱ رقم است که هرکدام یک عکس خاکستری ۱۶ در ۱۶ پیکسلی است. مقادیر پیکسل ها نرمال سازی شده اند تا در بازه ی  $[-1, 1]$  باشند.



شکل ۶: اعداد دست نویس از پایگاه داده خدمات پستی ایالات متحده

ما ارقام را به سه فرمت مختلف اما معادل بررسی خواهیم کرد:

۱. به عنوان تصاویر خاکستری مقیاس  $16 \times 16$ ،

۲. به عنوان توابعی از دو متغیر،  $s = s(x, y)$ ؛

۳. به عنوان بردارهایی در  $R^{256}$ .

برای طبقه بندی یک عدد ناشناخته، نیاز داریم فاصله آن را با اعداد شناخته شده محاسبه کنیم. انواع مختلفی از معیارهای فاصله را می توان استفاده کرد، اما شاید طبیعی ترین آن ها فاصله اقلیدسی<sup>۵</sup> باشد. ستون های تصویر را در یک بردار قرار دهید و هر رقم را به عنوان یک بردار در  $R^{256}$  شناسایی کنید. سپس تابع فاصله را به صورت زیر تعریف کنید:

$$(x, y) = \|x - y\|_2.$$

### ساختن یک پایه<sup>۶</sup>

برای ساختن یک پایه و الگوریتمی که هدف آن تشخیص یک رقم ناشناخته به یکی از کلاس های از پیش تعریف شده است، باید اطلاعاتی در مورد هر کلاس در الگوریتم گنجانده شود. این اطلاعات سپس در فرآیند طبقه بندی مورد استفاده قرار می گیرند. در مورد خاص ما، الگوریتم باید شامل اطلاعاتی درباره هر نوع رقم باشد و این اطلاعات از مجموعه آموزش استخراج می شود.

### بردار سازی تصویر:

ستون های تصویر  $16 \times 16$  را روی هم قرار دهید تا هر تصویر به یک بردار در فضای  $R^{256}$  تبدیل شود. هر عدد به شکل برداری  $x \in R^{256}$  نمایش داده می شود.

<sup>۵</sup>Euclidean Distance

<sup>۶</sup>Basis

## تابع فاصله:

برای استفاده از فاصله اقلیدسی از رابطه زیر استفاده می کنیم.

$$d(\mathbf{x}, \mathbf{y}) = \|\mathbf{x} - \mathbf{y}\|_2 = \sqrt{\sum_{i=1}^{256} (x_i - y_i)^2}$$

## تابع فاصله جایگزین:

به جای فاصله اقلیدسی، می توان از **فاصله کسینوسی** استفاده کرد. این معیار زاویه بین دو بردار را می سنجد و برای داده های نرمال شده مناسب است:

$$d_{\cosine}(\mathbf{x}, \mathbf{y}) = 1 - \frac{\mathbf{x} \cdot \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}$$

این تابع مقدار ۰ را نشان می دهد اگر بردارها کاملاً هم جهت باشند، و مقدار ۱ اگر کاملاً نامرتب باشند.

اگر مجموعه آموزش اعداد را به صورت بردارها یا نقاط در نظر بگیریم، منطقی است که فرض کنیم تمام اعداد از یک نوع خاص، یک خوشه از نقاط را در فضای برداری اقلیدسی ۲۵۶ - بعدی تشکیل می دهند.

در حالت ایده آل، این خوشه ها باید به خوبی از یکدیگر جدا باشند (در غیر این صورت، کار طبقه بندی اعداد ناشناخته بسیار دشوار خواهد بود).

## ۴.۳ یک الگوریتم ساده برای طبقه بندی

## آموزش:

با داشتن مجموعه آموزشی که به صورت دستی طبقه بندی شده است، میانگین ها (یا مراکز خوشه ها)  $\mathbf{m}_i$  برای  $i = 0, \dots, 9$  را برای تمام ۱۰ کلاس محاسبه کنید.

## طبقه بندی:

برای هر عدد در مجموعه تست، آن را به کلاس  $k$  نسبت دهید اگر  $\mathbf{m}_k$  نزدیک ترین میانگین باشد. دلیل عملکرد نسبتاً ضعیف این الگوریتم این است که هیچ اطلاعاتی درباره تغییرات درون هر کلاس از اعداد را در نظر نمی گیرد.

## ۵.۳ دسته بندی داده ها با پایه های SVD

در این بخش، یک الگوریتم طبقه بندی را توضیح خواهیم داد که بر اساس مدل سازی تغییرات درون هر کلاس عددی با استفاده از بردارهای پایه عمود بر هم که با استفاده از تجزیه مقادیر منفرد محاسبه می شوند، عمل می کند.


فرض کنید قصد داریم تغییرات درون یک کلاس خاص از تصاویر دست نویس (مانند عدد ۳) را مدل سازی کنیم. هر تصویر یک ماتریس  $16 \times 16$  است که نمایانگر پیکسل های تصویر است. هدف ما این است که تفاوت های موجود در دست نویس های مختلف عدد ۳ را شناسایی کرده و مدل کنیم.

### ساخت ماتریس $A$

ابتدا تمام تصاویر عدد ۳ را که در اختیار داریم، به صورت ستون به ستون در یک ماتریس بزرگ  $A$  قرار می دهیم. هر ستون از این ماتریس نمایانگر یک تصویر از عدد ۳ است. فرض کنید تعداد کل تصاویر  $N$  عدد ۳ در اختیار داریم. از آنجا که هر تصویر یک ماتریس  $16 \times 16$  است، هر تصویر به یک بردار ستونی  $256 \times 1$  تبدیل می شود. بنابراین، ماتریس  $A$  که شامل تمام این تصاویر است، به ابعاد  $256 \times N$  خواهد بود، به این صورت:

$$A = \begin{bmatrix} | & | & | & \dots & | \\ a_1 & a_2 & a_3 & \dots & a_N \\ | & | & | & \dots & | \end{bmatrix}$$

در اینجا،  $a_i$  نمایانگر یک تصویر از عدد ۳ است که به یک بردار ستونی تبدیل شده.



شکل ۷: مجموعه ای از ارقام همونوع تشکیل یک تنسور را می دهند.

برای درک این فرایند به عکس بالا دقت کنید.

### فضای زیرفضای خطی

ستون های ماتریس  $A$  یک زیرفضای خطی در فضای  $\mathbb{R}^{256}$  را می سازند. به عبارت دیگر، این ستون ها نشان دهنده ی مجموعه ای از الگوهای اصلی و ساختارهای موجود در دست نویس های مختلف عدد ۳ هستند. این زیرفضای خطی معمولاً کوچکتر از فضای کل خواهد بود، چرا که داده ها (تصاویر) ساختارمند و وابسته به یکدیگر هستند.

### استفاده از تجزیه مقادیر منفرد (SVD)

با استفاده از تجزیه مقادیر منفرد (SVD)، می توان ماتریس  $A$  را به صورت جمعی از ماتریس های رتبه-۱ نوشت:

$$A = \sum_{i=1}^m \sigma_i u_i v_i^T$$

در اینجا:

- $u_i$ : بردارهای منفرد چپ که پایه های زیرفضای خطی هستند. این بردارها الگوهای اصلی تغییرات رقم را مدل می کند و به آن تصاویر منفرد گفته می شود.
- $\sigma_i$ : مقادیر منفرد که میزان اهمیت هر بردار منفرد را نشان می دهند. درواقع نشان دهنده میزان اهمیت هر الگو می باشد.
- $v_i^T$ : بردارهای منفرد راست که نشان دهنده ی این هستند که هر تصویر چگونه با این الگوها ترکیب می شود.

مختصات تصویر  $j$  در ماتریس  $A$  بر اساس این پایه برابر با  $\sigma_i v_{ij}$  است. با توجه به خواص تقریب ماتریس در تجزیه SVD، می دانیم که اولین بردار منفرد  $u_1$  نمایانگر «جهت غالب» در ماتریس داده است. بنابراین، اگر بردارهای  $u_i$  را به تصاویر بازگردانیم، انتظار داریم که اولین بردار منفرد شبیه به یک رقم ۳ باشد، و تصاویر منفرد بعدی تغییرات غالب مجموعه آموزشی را حول اولین تصویر منفرد نشان دهند.

### مدل سازی تغییرات درون کلاس

بردارهای  $u_i$  به عنوان پایه های زیرفضای مربوط به کلاس خاصی از اعداد (مثلاً عدد ۳) در نظر گرفته می شوند. این بردارها به ما کمک می کنند تا تغییرات درون یک کلاس خاص (عدد ۳) را مدل کنیم. به عبارت دیگر، این روش تفاوت ها و تنوع های موجود در دست نویس های مختلف عدد ۳ را به صورت مؤثری نشان می دهد.

### کاربرد در تشخیص

فرض کنید که ماتریس های پایه برای تمام کلاس ها ساخته شده و در دسترس هستند. در این صورت، کدام مجموعه از پایه ها، یک رقم ناشناخته را توصیف می کند؟ برای طبقه بندی یک عدد ناشناخته، باید بررسی کنیم که چگونه این عدد می تواند در ۱۰ پایه مختلف (مربوط به ارقام مختلف) نمایش داده شود. این کار از طریق محاسبه بردار باقی مانده در مسئله کمترین مربعات به صورت زیر انجام می شود:

$$\min_{\alpha_i} \left\| z - \sum_{i=1}^k \alpha_i u_i \right\|_2,$$

که در آن:

•  $z$ : عدد ناشناخته است.

•  $u_i$ : تصاویر منفرد مربوط به هر کلاس هستند.

•  $\alpha_i$ : ضرایب ترکیب خطی تصاویر منفرد.

می توان این مسئله را به صورت ماتریسی بازنویسی کرد:

$$\min_{\alpha} \|z - U_k \alpha\|_2,$$

که در آن:

$$U_k = [u_1 \ u_2 \ \dots \ u_k].$$

از آنجا که ستون های ماتریس  $U_k$  متعامد هستند، راه حل این مسئله به صورت زیر داده می شود:

$$\alpha = U_k^T z.$$

نرم بردار باقی مانده مسئله کمترین مربعات برابر است با:

$$\|(I - U_k U_k^T) z\|_2,$$


که این مقدار بیانگر نرم تصویر عدد ناشناخته  $z$  بر زیر فضای متعامد با  $\text{span}(U_k)$  است. بردار باقی مانده نشان دهنده مقدار خطایی است که هنگام نمایش عدد ناشناخته در زیر فضای  $\text{span}(U_k)$  ایجاد می شود. برای هر کدام از ۱۰ کلاس (ارقام ۰ تا ۹)، این مقدار محاسبه شده و کلاس با کمترین مقدار بردار باقی مانده به عنوان پیش بینی طبقه بندی عدد ناشناخته انتخاب می شود.

در واقع، این روش کمک می کند تا تشخیص دقیق تری از اعداد مختلف داشته باشیم، چرا که نه تنها شکل کلی عدد، بلکه تفاوت های جزئی در دست نویس های مختلف را نیز در نظر می گیرد. برای نشان دادن اینکه فرضیات قبلی منطقی هستند، در شکل ۴ نرم باقی مانده نسبی برای تمامی اعداد ناشناخته ۳ و ۷ در ارتباط با ۱۰ پایه مختلف نمایش داده شده است. در این نمودارها، برای هر عدد ناشناخته یک منحنی رسم شده است. به طور طبیعی، مشاهده جزئیات تک تک منحنی ها ممکن نیست، اما می توان دید که بیشتر اعداد ناشناخته ۳ و ۷ به بهترین شکل ممکن در پایه مربوط به خود نمایش داده شده اند. این نمودارها همچنین اطلاعاتی درباره خطاهای احتمالی طبقه بندی ارائه می دهند. به عنوان مثال، اعداد ۳ و ۵ به یکدیگر شباهت بیشتری دارند، در حالی که اعداد ۳ و ۴ تفاوت های قابل توجهی دارند.

### الگوریتم طبقه بندی مبتنی بر پایه های SVD

با الگوریتم های متفاوتی می توان این دسته بندی را پیاده سازی نمود. در زیر یک مدل ساده از آن را آوردیم.





شکل ۸: نمودار نرم باقی مانده نسبی برای اعداد ناشناخته ۳ و ۷ در ارتباط با ۱۰ پایه مختلف.

### Algorithm ۱ الگوریتم طبقه بندی مبتنی بر پایه های SVD


آموزش:

**for** هر کلاس از ارقام شناخته شده **do**

محاسبه تجزیه مقادیر منفرد (SVD) برای ماتریس تصاویر ارقام آن کلاس طبقه بندی:

**for** عدد آزمون ناشناخته **do**


محاسبه باقی مانده نسبی در هر یک از ۱۰ پایه  
باقی مانده یکی از پایه ها به طور معناداری کوچک تر از سایر پایه ها باشد آنگاه عدد آزمون به کلاس متناظر تخصیص یابد.



شکل ۹:  $U_{10}$  برای ارقام صفر و یک

## ۴ فاصله تانژانت

یک الگوریتم طبقه‌بندی خوب باید قادر باشد ارقام ناشناخته‌ای را که به‌طور نسبتاً خوبی نوشته شده‌اند اما هنوز هم انحرافات قابل توجهی از رقم ایده‌آل در فاصله اقلیدسی دارند، طبقه‌بندی کند. برخی از این انحرافات وجود دارند که انسان‌ها می‌توانند به راحتی از پس آن‌ها برآیند و در واقع این نوع انحرافات کاملاً رایج و قابل قبول هستند. در شکل، چند نمونه از این تغییرات را نشان داده‌ایم.



شکل ۱۰: نمونه های دست نوشته

این نوع تغییرات برای یک خواننده انسانی مشکلی ایجاد نمی‌کند و در حالت ایده‌آل باید به راحتی در شناسایی خودکار ارقام نیز قابل مدیریت باشند. به عبارت دیگر، الگوریتم‌های شناسایی ارقام باید قادر باشند تغییرات کوچک و رایج در نحوه نوشتن ارقام را درک کرده و به درستی آن‌ها را شبیه‌سازی کنند، مشابه نحوه برخورد انسان‌ها با این تغییرات. تصاویر  $16 \times 16$  را می‌توان به عنوان نقاطی در  $\mathbb{R}^{256}$  تفسیر کرد. فرض کنید  $p$  یک الگوی ثابت در یک تصویر باشد. ابتدا حالت فقط یک تغییر مجاز، یعنی جابجایی الگو (رقم) در جهت محور  $x$ ، را در نظر می‌گیریم. این جابجایی را می‌توان به عنوان حرکت الگو در امتداد یک منحنی در  $\mathbb{R}^{256}$  در نظر گرفت. فرض کنید منحنی با یک پارامتر حقیقی  $\alpha$  پارامترسازی شود، به طوری که منحنی به شکل  $s(p, \alpha)$  داده شده و به گونه‌ای باشد که  $s(p, 0) = p$ . به طور کلی، منحنی غیرخطی است و می‌توان آن را با دو جمله اول در توسعه تیلور تقریب زد:


$$s(p, \alpha) = s(p, 0) + \frac{ds}{d\alpha}(p, 0)\alpha + O(\alpha^2) \approx p + t_p\alpha,$$

که در آن  $t_p = \frac{ds}{d\alpha}(p, 0)$  یک بردار در  $\mathbb{R}^{256}$  است. با تغییر اندک  $\alpha$  در اطراف ۰، یک حرکت کوچک از الگو در امتداد مماس در نقطه  $p$  روی منحنی انجام می‌دهیم. حال فرض کنید که یک الگوی دیگر به نام  $e$  به طور مشابه تقریب زده شده باشد:

$$s(e, \alpha) \approx e + t_e\alpha.$$

از آنجا که ما جابجایی‌های کوچک در امتداد منحنی‌ها را مجاز می‌دانیم، این جابجایی‌های کوچک نباید بر روی تابع فاصله تأثیر بگذارند. بنابراین، به طور ایده‌آل، ما می‌خواهیم معیار نزدیکی بین  $p$  و  $e$  را به عنوان نزدیک‌ترین فاصله بین دو منحنی تعریف کنیم.

اما از آنجا که به طور کلی نمی‌توانیم فاصله بین منحنی‌ها را محاسبه کنیم، می‌توانیم از تقریب‌های مرتبه اول استفاده کرده و نزدیک‌ترین فاصله بین دو مماس را در نقاط  $p$  و  $e$  محاسبه کنیم. بنابراین، الگوها را به طور مستقل در امتداد مماس‌های خود حرکت می‌دهیم تا کوچک‌ترین



شکل ۱۱: فاصله بین نقاط  $p$  و  $e$  و فاصله تانژانت

فاصله را پیدا کنیم. اگر این فاصله را با استفاده از معیاری اقلیدسی معمولی اندازه گیری کنیم، مسأله کمینه مربعات به شکل زیر حل می شود:

$$\min_{\alpha_p, \alpha_e} \|p + t_p \alpha_p - e - t_e \alpha_e\|^2 = \min_{\alpha_p, \alpha_e} \left\| (p - e) - \begin{pmatrix} -t_p & t_e \end{pmatrix} \begin{pmatrix} \alpha_p \\ \alpha_e \end{pmatrix} \right\|^2.$$

حال، فرض کنید که مجاز هستیم الگو  $p$  را در  $l$  منحنی مختلف در  $\mathbb{R}^{256}$  حرکت دهیم که با پارامتر  $\alpha = (\alpha_1, \dots, \alpha_l)^T$  پارامترسازی شده اند. این معادل با حرکت الگو در یک سطح  $l$ -بعدی در  $\mathbb{R}^{256}$  است. فرض کنید دو الگوی  $p$  و  $e$  داریم که هر یک مجاز به حرکت در سطح خود از تغییرات هستند. ایده آل این است که ما نزدیک ترین فاصله بین سطوح را پیدا کنیم، اما از آنجا که این محاسبه غیرممکن است، اکنون یک معیار فاصله تعریف می کنیم، جایی که فاصله بین دو صفحه مماس در نقاط  $p$  و  $e$  را محاسبه می کنیم. همانطور که قبل تر اشاره شد، صفحه مماس با دو جمله اول در توسعه تیلور تابع  $s(p, \alpha)$  داده می شود:

$$s(p, \alpha) = s(p, 0) + \sum_{i=1}^l \frac{ds}{d\alpha_i}(p, 0) \alpha_i + O(\alpha^2) \approx p + T_p \alpha,$$

که در آن  $T_p$  ماتریس است:

$$T_p = \left( \frac{ds}{d\alpha_1} \quad \frac{ds}{d\alpha_2} \quad \dots \quad \frac{ds}{d\alpha_l} \right),$$

و مشتقات همگی در نقطه  $(p, 0)$  محاسبه می شوند. بنابراین، فاصله مماس بین نقاط  $p$  و  $e$  به صورت کمترین باقی مانده در مسأله کمینه مربعات تعریف می شود:

$$\min_{\alpha_p, \alpha_e} \|p + T_p \alpha_p - e - T_e \alpha_e\|^2 = \min_{\alpha_p, \alpha_e} \left\| (p - e) - \begin{pmatrix} -T_p & T_e \end{pmatrix} \begin{pmatrix} \alpha_p \\ \alpha_e \end{pmatrix} \right\|^2.$$

مسأله کمینه مربعات را می‌توان با استفاده از تجزیه مقدار منفرد (SVD) ماتریس  $A = \begin{pmatrix} -T_p & T_e \end{pmatrix}$  حل کرد.

توجه داشته باشید که ما به دنبال حل خود مسأله نیستیم بلکه تنها به معیار باقی‌مانده علاقه داریم. مسأله کمینه مربعات را می‌توان به صورت زیر نوشت:

$$\min_{\alpha} \|b - A\alpha\|^2, \quad b = p - e, \quad \alpha = \begin{pmatrix} \alpha_p \\ \alpha_e \end{pmatrix}.$$

اگر از تجزیه QR استفاده کنیم:

$$A = Q \begin{pmatrix} R \\ 0 \end{pmatrix} = (Q_1 \ Q_2) \begin{pmatrix} R \\ 0 \end{pmatrix} = Q_1 R,$$

معیار باقی‌مانده به شکل زیر است:

$$\min_{\alpha} \|b - A\alpha\|^2 = \min_{\alpha} \|Q_1^T b - R\alpha\|^2 + \|Q_2^T b\|^2 = \|Q_2^T b\|^2.$$

موردی که در آن ماتریس  $A$  ممکن است رتبه کامل نداشته باشد به راحتی با استفاده از SVD قابل حل است؛ برای جزئیات بیشتر به بخش ۷.۶ مراجعه کنید. احتمالاً وقتی دو الگو به یکدیگر نزدیک هستند، ستون‌های ماتریس مماس تقریباً وابسته خطی خواهند بود. مهم‌ترین ویژگی این تابع فاصله این است که تحت جابجایی الگوها در صفحات مماس تغییر نخواهد کرد. به عنوان مثال، اگر یک جابجایی کوچک در جهت محور  $x$  از یک الگو انجام دهیم، با این معیار، فاصله‌ای که الگو جابجا شده برابر با صفر خواهد بود.

## ۱.۴ تبدیلات

در این بخش، الگوی تصویر را به‌عنوان یک تابع از دو متغیر  $p = p(x, y)$  در نظر می‌گیریم و نشان می‌دهیم که مشتق هر تبدیل را می‌توان به‌صورت یک عملگر مشتق‌گیری که ترکیب خطی از مشتقات  $p_x = \frac{\partial p}{\partial x}$  و  $p_y = \frac{\partial p}{\partial y}$  است، بیان کرد.

### انتقال

ساده‌ترین تبدیل، تبدیلی است که در آن الگو به میزان  $\alpha_x$  در جهت  $x$  جابجا می‌شود، یعنی


$$s(p, \alpha_x)(x, y) = p(x + \alpha_x, y).$$

با استفاده از قانون زنجیره، داریم

$$\left. \frac{d}{d\alpha_x} (s(p, \alpha_x)(x, y)) \right|_{\alpha_x=0} = \left. \frac{d}{d\alpha_x} p(x + \alpha_x, y) \right|_{\alpha_x=0} = p_x(x, y).$$

در شکل، یک الگو و مشتق آن در جهت  $x$  را نشان می‌دهیم. سپس نشان می‌دهیم که با افزودن یک ضرب کوچک از مشتق، الگو می‌تواند به چپ یا راست منتقل شود. به‌طور مشابه، برای ترجمه در جهت  $y$ ، داریم

$$\left. \frac{d}{d\alpha_y} (s(p, \alpha_y)(x, y)) \right|_{\alpha_y=0} = p_y(x, y).$$



شکل ۱۲: الگو، مشتق آن در جهت  $x$  و ترجمه‌های  $x$  الگو

### چرخش

چرخش. چرخش یک الگو به زاویه  $\alpha_r$  با جایگزینی مقدار  $p$  در نقطه  $(x, y)$  با مقدار در نقطه

$$\begin{pmatrix} \cos \alpha_r & \sin \alpha_r \\ -\sin \alpha_r & \cos \alpha_r \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}$$

انجام می‌شود. بنابراین ما تابع

$$s(p, \alpha_r)(x, y) = p(x \cos \alpha_r + y \sin \alpha_r, -x \sin \alpha_r + y \cos \alpha_r)$$

را تعریف می‌کنیم و مشتق آن را به صورت

$$\frac{d}{d\alpha_r} (s(p, \alpha_r)(x, y)) = (-x \sin \alpha_r + y \cos \alpha_r) p_x + (-x \cos \alpha_r - y \sin \alpha_r) p_y$$

به دست می‌آوریم. با قرار دادن  $\alpha_r = 0$ ، داریم

$$\left. \frac{d}{d\alpha_r} (s(p, \alpha_r)(x, y)) \right|_{\alpha_r=0} = yp_x - xp_y$$

که در آن مشتقات در نقطه  $(x, y)$  ارزیابی می‌شوند.



شکل ۱۳: الگو، مشتق دورانی آن، و چرخش الگو


### مقیاس بندی

یک مقیاس بندی از الگو با تعریف تابع زیر به دست می‌آید:

$$s(p, \alpha_s)(x, y) = p((1 + \alpha_s)x, (1 + \alpha_s)y),$$

و مشتق آن به صورت زیر است:

$$\left. \frac{d}{d\alpha_s} (s(p, \alpha_s)(x, y)) \right|_{\alpha_s=0} = x \frac{\partial p}{\partial x} + y \frac{\partial p}{\partial y}.$$



شکل ۱۴: الگو، مشتق اسکیلینگ آن و "اسکیلینگ به بالا" الگو

### ضخیم‌سازی

الگو می‌تواند با استفاده از تکنیک‌های مشابه نازک‌تر یا ضخیم‌تر شود؛ برای جزئیات بیشتر، به [۸۷] مراجعه کنید. مشتق "ضخیم‌سازی" به صورت زیر است:

$$\left(\frac{\partial p}{\partial x}\right)^2 + \left(\frac{\partial p}{\partial y}\right)^2.$$

---

### Algorithm ۲ الگوریتم طبقه‌بندی مبتنی بر فاصله تانژانت

---

آموزش:

**for** برای هر رقم در مجموعه آموزشی **do**  
ماتریس تانژانت  $T_p$  را محاسبه کنید  
طبقه‌بندی:

**for** برای هر رقم آزمایشی **do**  
ماتریس مماس آن را محاسبه کنید؛ فاصله مماس را با تمام ارقام آموزشی محاسبه کرده و رقم  
آزمایشی را به عنوان نزدیک‌ترین رقم آموزشی دسته‌بندی کنید.

---

## ۵ نتیجه‌گیری

در این پژوهش، تجزیه مقادیر منفرد (SVD) به‌عنوان یکی از روش‌های کلیدی برای بهبود پردازش داده‌ها مورد بررسی قرار گرفت. این روش با تجزیه یک ماتریس به سه مولفه‌ی اصلی  $U$ ،  $\Sigma$  و  $V^T$ ، امکان کاهش پیچیدگی داده‌ها و تمرکز بر اطلاعات مهم و ضروری را فراهم می‌کند. از جمله مزایای این روش می‌توان به حفظ ویژگی‌های اصلی داده، کاهش نویز و حذف اطلاعات کم‌اهمیت اشاره کرد.

در روند این تحقیق، کاربردهای SVD در تحلیل داده‌های پیچیده و بزرگ، خصوصاً در زمینه‌های یادگیری ماشین و هوش مصنوعی، برجسته شد. این تکنیک علاوه بر کاهش ابعاد، نقش کلیدی در افزایش دقت مدل‌های یادگیری، کاهش سربار محاسباتی و بهبود عملکرد کلی سیستم دارد. همچنین، استفاده از فاصله تانژانت به‌عنوان یک معیار در ارزیابی شباهت و تفکیک‌پذیری داده‌ها نشان داد که این متریک می‌تواند در بسیاری از سناریوها منجر به ارتقاء دقت طبقه‌بندی و تحلیل داده شود.

از دیگر دستاوردهای این پژوهش، امکان بازسازی دقیق ماتریس اصلی از مولفه‌های  $U$ ،  $\Sigma$  و  $V^T$  بود که نشان‌دهنده قدرت بالای SVD در حفظ ساختار و اطلاعات داده است. علاوه بر این، تحلیل رفتار داده‌ها پس از کاهش ابعاد و ارزیابی اثرات نویز در داده‌های اصلی و کاهش‌یافته، اهمیت این روش را در کاربردهای متنوع از جمله بینایی ماشین، تحلیل متون، و پردازش سیگنال بیش از پیش نشان داد.

به طور کلی، نتایج این پژوهش بر اهمیت این روش و مزایای آن در پردازش داده‌ها تأکید دارد. این روش نه تنها موجب کاهش پیچیدگی داده‌ها می‌شود، بلکه با حفظ اطلاعات کلیدی، در بهبود عملکرد مدل‌های یادگیری و تحلیل داده‌ها نقش بسزایی ایفا می‌کند. آینده این روش در تلفیق با دیگر تکنیک‌های پیشرفته، مانند شبکه‌های عصبی و یادگیری عمیق، نویدبخش پیشرفت‌های چشمگیری در حوزه تحلیل داده و هوش مصنوعی است.



## مراجع

- [1] Eldén, L., Matrix Methods in Data Mining and Pattern Recognition
- [2] Berkant Savas, Analyses and Tests of Handwritten Digit Recognition Algorithms
- [3] <http://www.gaussianprocess.org/gpml/data/>